

Линейная классификация и информативное векторное представление



Радослав Нейчев



Mapa Mundi
Мир машинного обучения
и искусственного интеллекта

Лекция 2 • Линейные модели



Что в этой лекции?

- Правдоподобие и его связь с логистической функцией потерь и кросс-энтропией
- Бинарная и многоклассовая классификация
- Как строить информативные векторные представления различных объектов
- Как строить такие представления для слов в языке

Ещё раз: правдоподобие

Фиксируем данные, сравниваем
параметры

01

Простой пример: подбрасываем монетку

Орёл кодируем единицей, решку – нулём. Наблюдаем четыре единицы и один ноль.

$$\mathcal{D} = (1, 1, 1, 1, 0), \quad p = P(y = 1)$$

$$\mathcal{L}(0,8; \mathcal{D}) = 0,8 \cdot 0,8 \cdot 0,8 \cdot 0,8 \cdot 0,2$$

$$\mathcal{L}(0,8; \mathcal{D}) = 0,8^4 \cdot 0,2 = 0,08192$$

- Перемножаем вероятности именно тех исходов, которые увидели.

Другая модель для той же монетки

Данные не меняются. Меняем только предполагаемую вероятность орла p .

$$\mathcal{L}(0,3; \mathcal{D}) = 0,3 \cdot 0,3 \cdot 0,3 \cdot 0,3 \cdot 0,7$$

$$\mathcal{L}(0,3; \mathcal{D}) = 0,3^4 \cdot 0,7 = 0,00567$$

$$0,08192 > 0,00567$$

- При этих данных модель с $p = 0,8$ назначает наблюдаемой последовательности большую вероятность.

Что такое правдоподобие?

Правдоподобие показывает, какую вероятность модель с параметрами θ назначает уже наблюдаемым ответам. При произведении считаем ответы условно независимыми.

$\mathbf{x}^{(i)}$ – признаки объекта, $y^{(i)}$ – ответ; n – число объектов, θ – параметры модели.

$$\mathcal{D} = \{(\mathbf{x}^{(i)}, y^{(i)})\}_{i=1}^n$$

$$\mathcal{L}(\theta; \mathcal{D}) = \prod_{i=1}^n p_{\theta}(y^{(i)} \mid \mathbf{x}^{(i)})$$

- Данные $\mathcal{D}$ зафиксированы. Это функция параметров, а не вероятность параметров после наблюдения данных.

От произведения к сумме

Максимум правдоподобия равносильно минимуму отрицательного логарифма.

θ^* – параметры в точке максимума; Q – среднее значение функции потерь по выборке.

$$\theta^* = \arg \max_{\theta} \mathcal{L}(\theta; \mathcal{D})$$

$$Q(\theta) = -\frac{1}{n} \sum_{i=1}^n \log p_{\theta} \left(y^{(i)} \mid \mathbf{x}^{(i)} \right)$$


- Логарифм сохраняет точку максимума и превращает произведение в сумму.

Рассмотрим бинарную классификацию

От сора к вероятности класса

02

Скор линейной модели



$$z = \mathbf{w}^T \mathbf{x} + b$$

$$z > 0 \Rightarrow \hat{y} = 1$$

$$z < 0 \Rightarrow \hat{y} = 0$$


b – свободный член
Вектор весов перпендикулярен
разделяющей гиперплоскости.

● $y = 1$

× $y = 0$

Отступ объекта

$$\mathbf{w} = (1, 0)^T, \quad b = 0, \quad z = x_1$$



Классы:  $y = 1$  $y = 0$


$$m = \begin{cases} z, & y = 1, \\ -z, & y = 0. \end{cases}$$

Объект	y	z	m
A	1	2	2
B	0	-2	2
C	1	-1	-1

$m > 0$: верно; $m < 0$: ошибка

- Функциональный отступ зависит от масштаба весов; расстояние до границы равно $|z|/\|\mathbf{w}\|_2$.

Сигмоида



$$\sigma(z) = \frac{1}{1 + e^{-z}}$$

$$0 < \sigma(z) < 1$$

$$\sigma(0) = \frac{1}{2}$$

$$\sigma(-z) = 1 - \sigma(z)$$

$$\sigma'(z) = \sigma(z)(1 - \sigma(z))$$

$$p(y = 1 \mid \mathbf{x}) = \sigma(z)$$

Правдоподобие и параметры модели



6 объектов; красные кружки: $y = 1$, синие крестики: $y = 0$

$$\mathbf{w} = 2(\cos \alpha, \sin \alpha)^T, \quad b = 0$$

$$\mathcal{L}(\mathbf{w}, b) = \prod_{i=1}^6 p(y^{(i)} \mid \mathbf{x}^{(i)}; \mathbf{w}, b)$$

Сейчас: **0,39551**

α	$\mathbf{w}^T$	$\mathcal{L}(\mathbf{w}, 0)$
0°	(2,00; 0,00)	0,39551
60°	(1,00; 1,73)	0,10436
120°	(-1,00; 1,73)	0,00084

Данные не меняются. Для разных параметров получаем разное правдоподобие.

Бинарная кросс-энтропия (cross-entropy)

Значение функции потерь – минус логарифм вероятности наблюдаемого класса.

$$\ell(y, p) = -y \log p - (1 - y) \log(1 - p)$$

$$\ell(y, p) = \begin{cases} -\log p, & y = 1, \\ -\log(1 - p), & y = 0. \end{cases}$$

- p – вероятность класса 1, которую выдала модель.

Логистическая функция потерь

Подставляем вероятность $p = \sigma(z)$ в бинарную кросс-энтропию.

$$p = \sigma(z)$$

$$\ell(y, z) = \begin{cases} \log(1 + e^{-z}), & y = 1, \\ \log(1 + e^z), & y = 0. \end{cases}$$

$$\ell(m) = \log(1 + e^{-m})$$

- $m = z$ при $y = 1$ и $m = -z$ при $y = 0$. Поэтому обе строки записываются одной формулой через отступ.

Производная логистической функции потерь

Для положительного объекта производная равна $\sigma(z) - 1$, для отрицательного $-\sigma(z)$.

$$\frac{\partial \ell}{\partial z} = \sigma(z) - y$$

- Знак производной показывает, в какую сторону надо изменить скор.

Как один пример меняет модель

Метка	Скор z	$\sigma(z)$	$\partial\ell/\partial z$	Направление шага
$y = 1$	-1	0,269	$-0,731$	увеличить z
$y = 0$	1	0,731	0,731	уменьшить z

Что если объект далеко от границы класса?

Для положительного объекта $z = 4$. Каково значение производной функции потерь по z ?

- $\sigma(4) - 1 \approx -0,018$. Производная по скору мала.

Многоклассовая классификация

03

Свой классификатор для каждого класса

Объект задан вектором $\mathbf{x} \in \mathbb{R}^d$. Для C классов настраиваем C векторов весов $\mathbf{u}_1, \dots, \mathbf{u}_C$.

$$z_c = \mathbf{u}_c^T \mathbf{x} + b_c, \quad c \in \{1, \dots, C\}$$

$$\hat{y} = \arg \max_c z_c$$

- b_c остаётся отдельным свободным членом классификатора класса c .

Все классификаторы в одной матрице

Строка c матрицы $\mathbf{W}$ содержит параметры классификатора класса c .

$$\mathbf{W} = \begin{pmatrix} \mathbf{u}_1^T \\ \vdots \\ \mathbf{u}_C^T \end{pmatrix} \in \mathbb{R}^{C \times d}, \quad \mathbf{b} \in \mathbb{R}^C$$

$$\mathbf{z} = \mathbf{W}\mathbf{x} + \mathbf{b}$$

- Вектор $\mathbf{z} \in \mathbb{R}^C$ содержит скоры всех классов.

Softmax

Сначала требуем корректное распределение вероятностей по C классам. Softmax преобразует скоры z_c в такие вероятности.

$$\begin{cases} 0 \leq p_c \leq 1, & c = 1, \dots, C, \\ \sum_{c=1}^C p_c = 1. \end{cases}$$

$$p_c = p(y = c \mid \mathbf{x}) = \frac{e^{z_c}}{\sum_{j=1}^C e^{z_j}}$$

- Каждый класс участвует в знаменателе.

Три класса: численный пример

Класс	z_c	e^{z_c}	p_c
Класс 1	2	7,39	0,665
Класс 2	1	2,72	0,245
Класс 3	0	1	0,090
Сумма			1,000

Значение функции потерь

Если верен класс 2, то $\ell = -\log 0,245 \approx 1,41$.

$$\ell(y, \mathbf{z}) = -\log p(y \mid \mathbf{x})$$

$$\frac{\partial \ell}{\partial z_c} = p_c - \mathbb{I}[c = y]$$

- Скор верного класса нужно увеличить, скоры остальных классов – уменьшить.

Скоры всех классов влияют на вероятность каждого

Вероятность класса зависит от его сора и от скоров всех остальных классов в знаменателе softmax.

- Для неверного класса производная по z_c равна p_c . При малой вероятности она мала, но не равна нулю.

Какие величины мы настраиваем

Вход

Вектор признаков $\mathbf{x}$ задан заранее

Его не обучаем вместе с классификатором

Параметры

Обучаем $\mathbf{u}_c$ и b_c для каждого класса

Из них получаем скоры z_c

- Пока настраиваем только параметры классификатора.

Категориальные признаки

Категориальная переменная

Принимает одно значение из конечного набора

Между категориями нет естественного порядка, как и между метками классов

One-hot для цвета

Красный: (1, 0, 0)

Зелёный: (0, 1, 0)

Синий: (0, 0, 1)

Каждой категории соответствует отдельная координата

- Код 1, 2, 3 создал бы искусственный порядок между цветами.

Что такое токен?

Токен – один элемент, полученный при разбиении текста на части.

Исходный текст

«кот мирно спит»

Последовательность символов

После токенизации

кот · мирно · спит

В примере получилось три токена

- На этой лекции один токен – одно слово.

One-hot представление токена

Слова (токены) – тоже категориальные значения. Кодлируем их one-hot: V – размер словаря; здесь $V = 4$.

$$\mathbf{o}_{\text{кот}} = (1, 0, 0, 0)^T$$

$$\mathbf{o}_{\text{пёс}} = (0, 1, 0, 0)^T$$

Мысленный эксперимент: заполните пропуск

«Василий пил кофе с ____, и ему было очень сладко». На место пропуска подходят «сахаром» или «шоколадкой» заметно лучше многих других слов.


- Однозначного ответа может не быть. Контекст меняет условные вероятности слов.

Простой пример

Предложение	Повторов
кот ест корм	2
пёс ест корм	2
кот мирно спит	1
пёс мирно спит	1
самолёт быстро летит	1

Положительные примеры – пары в одном контексте

Берём одно слово слева и одно справа от центрального.



Почему похожие контексты нас интересуют

Наблюдение в тексте

У слов «кот» и «пёс» одинаковые контексты:
«ест» встречается дважды, «мирно» – один раз

Гипотеза о представлении

Если слова встречаются в похожих контекстах, их векторные представления также должны быть похожи

Эту гипотезу требуется проверить после обучения

- При этом «кот» и «пёс» ни разу не стоят рядом в учебном корпусе.

Как строить информативные представления (эмбеддинги)

04

Построение полной таблицы совстречаемости слов

Центр	ест	корм	мирно	спит	быстро	летит
кот	2	0	1	0	0	0
пёс	2	0	1	0	0	0
самолёт	0	0	0	0	1	0

Фрагмент матрицы совстречаемости **A**. Минус: при $V = 100\,000$ у каждого слова $100\,000$ координат, а в полной матрице 10^{10} ячеек. Вектор информативный, но огромный.

Частые слова встречаются во многих контекстах

Высокая совстречаемость может отражать характерную связь слов или просто высокую частоту контекстного слова.

- Поэтому значения таблицы часто нормируют относительно фоновой частоты. Здесь оставлена обычная частота пары, чтобы сохранить прозрачный пример.

Можем воспользоваться матричными разложениями

$\mathbf{A}$ – матрица совстречаемости, A_{wc} – частота пары (w, c) . Строка w матрицы $\mathbf{Q}$ равна $\mathbf{e}_w^T$, а строка c матрицы $\mathbf{U}$ равна $\mathbf{u}_c^T$.

$$\begin{array}{|c|} \hline \mathbf{A} \\ \hline V \times V \end{array} \approx \begin{array}{|c|} \hline \mathbf{Q} \\ \hline V \times d \end{array} \times \begin{array}{|c|} \hline \mathbf{U}^T \\ \hline d \times V \end{array}$$

$$A_{wc} \approx \mathbf{e}_w^T \mathbf{u}_c, \quad d \ll V$$

- SVD, UV-факторизация. Разложение Холецкого – для симметричных положительно определённых матриц.

Эта функция потерь приводит к SVD

Приближаем матрицу $\mathbf{A}$ матрицей $\hat{\mathbf{A}}$ ранга не выше d . Складываем квадраты ошибок во всех ячейках.

$$\min_{\text{rank}(\hat{\mathbf{A}}) \leq d} \sum_{w=1}^V \sum_{c=1}^V (A_{wc} - \hat{A}_{wc})^2$$

- Решение даёт усечённое SVD: оставляем d наибольших сингулярных значений.

Что получилось после разложения

Полная строка $A[w, :]$

V координат совстречаемости

Для большого словаря хранить и пересчитывать дорого

Строка $Q[w, :] = \mathbf{e}_w^T$

d координат, где $d \ll V$

Это компактное представление слова

- В случае усечённого SVD строки описываются через проекцию на найденное подпространство.


Можно ли обучать эмбединги?

Можно

05

По индексу берём строку таблицы

One-hot вектор выбирает строку матрицы представлений.



Оценка вероятности и подсчёт loss'a

s_{wc} – скор контекстного класса c для центрального слова w . Softmax превращает V скоров в вероятности.

$$s_{wc} = \mathbf{u}_c^T \mathbf{e}_w$$

$$p(c \mid w) = \frac{\exp(s_{wc})}{\sum_{j=1}^V \exp(s_{wj})}$$

$$\ell(w, c) = -\log p(c \mid w)$$

Что изменилось в классификаторе

Обычная классификация

x задан заранее

u_c обучается как вес класса

Skip-gram

e_w берётся из обучаемой таблицы

u_c обучается как вектор контекстного слова

- Градиент меняет обе стороны скалярного произведения.

Одно слово играет две роли

Где встретилось слово	Таблица	Вектор
в центре окна	Q	e_w
в контексте другого слова	U	u_c

Одна пара в словаре из трёх кандидатов

Кандидат c	скор s_{wc}	$p(c \mid w)$	производная по s_{wc}
ест (верный)	2	0,665	−0,335
корм	1	0,245	0,245
летит	0	0,090	0,090

Softmax перебирает весь словарь

Для одной обучающей пары в знаменатель входят все V контекстных СЛОВ.

- Нужно вычислить скоры для каждого кандидата, хотя в корпусе мы наблюдали только одно контекстное слово.

Что требуется от скоров контекстов

- Скор наблюдаемого контекста требуется увеличить относительно остальных
- Все контекстные слова участвуют в знаменателе softmax
- Один вектор слова используется во всех парах с этим центральным словом
- Функция потерь не задаёт целевые евклидовы расстояния между словами.

Положительные пары и пары из шума

Бинарная классификация вместо
нормировки по словарю

06

Какие пары получают метки 1 и 0

Пара из окна

$y = 1$: пара взята из текста

Например, (кот, ест)

Случайная пара

$y = 0$: контекст выбран случайно

В учебном варианте $q(c) = 1/V$ для каждого слова

- $q(c)$ – вероятность выбрать слово c шумовой процедурой. При равномерном выборе каждое слово имеет вероятность $1/V$.

Отличаем пару из текста от случайной пары

Берём пару (w, c) из текста и k случайных контекстов $n_1, \dots, n_k$. Оцениваем вероятность метки «пара из текста».

$$P(y = 1 \mid w, c) = \sigma(s_{wc}), \quad s_{wc} = \mathbf{u}_c^T \mathbf{e}_w$$

$$\ell_{\text{NS}} = -\log \sigma(s_{wc}) - \sum_{i=1}^k \log \sigma(-s_{wn_i})$$

- Это не вероятность того, что слова вообще встретятся рядом, и не $p(c \mid w)$ из full softmax.

Три бинарных примера на одном шаге

Пара	y	s	$P(y = 1 \mid w, c)$	$\partial \ell / \partial s$
(кот, ест)	1	1,2	0,769	-0,231
(кот, летит)	0	0,8	0,690	0,690
(кот, быстро)	0	-1,0	0,269	0,269

Откуда взялись значения s

Это отдельная учебная инициализация, не продолжение примера с реконструкцией.

$$\mathbf{e}_{\text{кот}} = (1, 0,5)^T$$

$$\mathbf{u}_{\text{ест}} = (0,8, 0,8)^T, \quad \mathbf{u}_{\text{летит}} = (0,4, 0,8)^T, \quad \mathbf{u}_{\text{быстро}} = (-0,8, -0,4)^T$$

$$s = (1,2, 0,8, -1,0)$$

- Каждое значение s – скалярное произведение центрального и выбранного контекстного векторов.

Какие векторы меняются

Индекс j перебирает один контекст из текста и k выбранных шумовых контекстов.

$$j \in \{c, n_1, \dots, n_k\}$$

$$\frac{\partial \ell}{\partial \mathbf{e}_w} = \sum_j (\sigma(s_{wj}) - y_j) \mathbf{u}_j$$

$$\frac{\partial \ell}{\partial \mathbf{u}_j} = (\sigma(s_{wj}) - y_j) \mathbf{e}_w$$

- Обновляется центральный вектор и выбранные на шаге контекстные векторы.

Что получилось после шага с $\eta = 0,1$

Все градиенты посчитаны по старым векторам, затем одновременно обновлены $\mathbf{e}_{\text{кот}}$ и три выбранных $\mathbf{u}_j$.

$$\mathbf{u}_{\text{ест}}^{\text{new}} = (0,823, 0,812)^T$$

$$\nabla_{\mathbf{e}} \ell = (-0,124, 0,259)^T, \quad \mathbf{e}_{\text{кот}}^{\text{new}} = (1,012, 0,474)^T$$

$$\ell : 1,748 \longrightarrow 1,665$$

- Новые значения s : 1,218, 0,698, $-1,033$.

Посмотрим на обучение 15 слов

Фрагменты искусственного корпуса

кот · пёс · волк · лиса · медведь


яблоко · груша · слива · вишня · персик

поезд · автобус · трамвай · метро · такси


Для каждого списка берём четыре порядка слов. Окно – два слова слева и справа. Из этих последовательностей получаем пары для обучения.

Как меняются векторы при обучении

До обучения · шаг 0



После обучения · шаг 1200



Шаг обучения

Среднее значение функции потерь: **3,986** → **0,363**

15 слов, искусственный корпус. Векторы двумерные. Цвета не участвуют в обучении.

Если шумовая пара уже хорошо отделена

При достаточно низком s эта пара всё слабее влияет на следующий шаг.

$$\ell_{-}(s) = \log(1 + e^s)$$

$$\frac{d\ell_{-}}{ds} = \sigma(s)$$

$$s \rightarrow -\infty \quad \Rightarrow \quad \sigma(s) \rightarrow 0$$

- Жёсткого порога нет: при любом конечном s градиент остаётся ненулевым.

Full softmax и negative sampling отвечают на разные вопросы

	Full softmax	Negative sampling
Что предсказывается	какое слово оказалось в контексте	из текста или из шума пришла пара
Выход	$p(c \mid w)$	$P(y = 1 \mid w, c)$
Что участвует в шаге	все V контекстов	одна пара из текста и k случайных пар

Как на практике выбирают случайные слова

$f(c)$ – эмпирическая частота контекстного слова c в обучающем корпусе. Формула нормирует веса и задаёт распределение q .

$$q(c) = \frac{f(c)^{3/4}}{\sum_{j=1}^V f(j)^{3/4}}$$

- Степень $3/4$ уменьшает перевес самых частых слов по сравнению с выбором пропорционально частоте.

Обучение закончилось. Что забираем?

Две таблицы обучались вместе;
теперь выбираем представление
слова и проверяем результат


07

Какой из двух векторов забрать?

- Строка $\mathbf{Q}[w, :]$ описывала слово в центре окна
- Строка $\mathbf{U}[w, :]$ описывала то же слово в роли контекста
- Выбор $\mathbf{Q}$, $\mathbf{U}$ или их комбинации проверяется в задаче, где будут использоваться векторы
- Универсально лучшего варианта нет.

Косинусное сходство

Косинус зависит от угла, а не от длины вектора.



$$\cos(\mathbf{a}, \mathbf{b}) = \frac{\mathbf{a}^T \mathbf{b}}{\|\mathbf{a}\|_2 \|\mathbf{b}\|_2}$$

$$\mathbf{a} = (2, 0)$$

$$\mathbf{b}_1 = (1, 1), \quad \mathbf{b}_2 = (3, 3)$$

$$\cos(\mathbf{a}, \mathbf{b}_1) = \cos(\mathbf{a}, \mathbf{b}_2) = \frac{1}{\sqrt{2}}$$

$$\|\mathbf{a} - \mathbf{b}_1\|_2 = \sqrt{2}$$

$$\|\mathbf{a} - \mathbf{b}_2\|_2 = \sqrt{10}$$

Посчитаем сходство в двух координатах

Слово	е	Косинусное сходство с «КОТ»
КОТ	(1, 1)	1
пёс	(0,9, 1,1)	0,995
самолёт	(−1, 0)	−0,707

Почему «кот» и «пёс» могут оказаться рядом?

Оба слова помогают предсказывать «ест» и «мирно». Поэтому их центральные векторы много раз обновляются через одни и те же контекстные векторы.

- Направления могут сблизиться, но это не гарантия: результат зависит от корпуса, окна, шума и хода оптимизации.

Как получить список ближайших слов

01

Запрос

Берём e_w

02

Сравнение

Считаем cosine с другими словами

03

Ранжирование

Выбираем top- k

04

Проверка

Смотрим на соседей в контексте нашей задачи

Как читать список соседей

- На маленьком корпусе хорошие семантические соседи могут не появиться
- Размер окна, частоты и распределение шума меняют результат
- Векторы воспроизводят закономерности и перекосы корпуса
- Сходство, полезное в одной прикладной задаче, может не помочь в другой

Задачу решили – представление осталось

Координаты эмбединга никто не задавал вручную. Для предсказания контекста модели пришлось подобрать векторы слов – строки матрицы Q .

- Предсказывающую часть можно отложить, а матрицу Q – таблицу обученных векторов слов – использовать в других задачах.

Три постановки, которые не надо смешивать

Постановка	Что дано	Что минимизируется
классификация	$(\mathbf{x}, y)$	отрицательный логарифм вероятности класса
факторизация	полная матрица $\mathbf{A}$	квадрат нормы Фробениуса ошибки реконструкции
skip-gram NS	пары из окна и шума	сумма значений логистической функции потерь

Проверим цепочку целиком

- Как из строки текста получить пару (центральное слово, контекст)?
- Почему full softmax и negative sampling решают разные задачи?
- Зачем одному слову две строки – в **Q** и в **U**?
- По этим трём ответам восстанавливается путь от корпуса до вектора слова.

ОСНОВНЫЕ ИСТОЧНИКИ

Mikolov et al., 2013

Skip-gram, hierarchical softmax и negative sampling

Levy & Goldberg, 2014

Неявная матричная факторизация SGNS

Deep Learning Book, notation

Соглашения по обозначениям

Mapra Mundi
Мир машинного обучения
и искусственного интеллекта

Лекция 3 • Векторы слов

Долина представлений
Векторы слов

One-hot

Арка SVD

МЫ ЗДЕСЬ

Word2vec

skip-gram • negative sampling

король
+
королева

париж
→
франция

Косинусное
сходство

Врата вероятностей

sigmoid • softmax

Размеченные
равнины

Террасы
линейных моделей

Регрессия

Классификация

Бастيون
регуляризации

Озеро
переобучения

Посёлок
ближайших соседей
kNN

Перевал
обобщения

Маяк
валидации

Спуск градиента
Функции потерь

MSE • MAE
log loss



Вопросы?

Спасибо!

Подписывайтесь на канал

[@rads_ai](#)

